# VILNIUS TECH

Intelektualiosios sistemos

# KOLOKVIUMO ATASKAITA

## Kredito įsipareigojimų nevykdymo rizikos prognozavimo įgyvendinimo planas

Studentė: Meila Andriuškevičiūtė
Grupė: DISfm-26
2026–2027 m. m.

Vilnius, 2026

# 1. Problemos formulavimas

Darbo tikslas – pagal kredito kortelės kliento istorinius duomenis įvertinti kalibruotą tikimybę, kad klientas kitą mėnesį nevykdys finansinių įsipareigojimų. Modelis vertinamas kaip sprendimų palaikymo priemonė, o ne automatinė galutinio kredito sprendimo sistema. Naudojamas UCI „Default of Credit Card Clients“ rinkinys: 30 000 klientų, iš kurių 6 636 (22,12 %) priklauso įsipareigojimų nevykdymo klasei [1].

## 1.1. Probleminės vietos ir neaiškumai

- Modelio pasirinkimas: nėra iš anksto aišku, ar sudėtingesnis XGBoost, Random Forest ar MLP reikšmingai pranoks lengviau paaiškinamą logistinę regresiją.
- Klasių disbalansas: default atvejų mažiau, todėl vien accuracy gali sudaryti klaidingą gero veikimo įspūdį; svarbesnės PR-AUC, Brier score ir kalibracija.
- Tikimybių patikimumas: geras klientų surikiavimas pagal riziką dar nereiškia, kad prognozuota 0,30 tikimybė realiai atitinka apie 30 % įvykių dažnį.
- Sprendimo slenkstis ir klaidų kaina: false negative gali lemti finansinį nuostolį, o false positive – nepagrįstą patikimo kliento ribojimą.
- Teisingumas: demografiniai požymiai gali veikti kaip jautrių savybių ar jų proxy kintamieji, todėl reikia vertinti modelio veikimą grupėse.
- Perkeliamumas: duomenys surinkti Taivane 2005 m., todėl rezultatų negalima automatiškai laikyti reprezentatyviais dabartinei Lietuvos rinkai.

## 1.2. Problemos išskaidymas į uždavinius

Problema skaidoma į šešis etapus: (1) duomenų gavimas ir kokybės patikra; (2) duomenų paruošimas ir stratifikuotas skaidymas; (3) baseline ir intelektualiųjų modelių mokymas; (4) tikimybių kalibravimas; (5) modelių vertinimas pagal diskriminaciją, kalibraciją, klaidų kainą ir grupes; (6) galutinio modelio bei sprendimo slenksčio parinkimas. Duomenų analitikui svarbiausi 1–5 etapai, programuotojui – atkuriama duomenų ir modelių grandinė, o rizikos specialistui – klaidų kainos ir slenksčio interpretacija.

## 1.3. Uždavinio prasmė skirtingiems specialistams

Techniniu požiūriu tai dvejetainės klasifikacijos ir tikimybės prognozavimo uždavinys. Projekto vadovui svarbu, ar sprendimas yra įgyvendinamas ir atkuriamas; finansų specialistui – kiek kainuoja klaidingi sprendimai; vadybininkui – ar prognozuotą riziką galima aiškiai interpretuoti; atitikties ar personalo specialistui – ar demografiniai požymiai nesukuria nepagrįstai skirtingų rezultatų grupėms. Todėl modelis vertinamas ne viena metrika, o keliomis tarpusavyje papildančiomis kryptimis.

# 2. Duomenys, įvestis ir išvestis

Duomenų šaltinis – viešas UCI „Default of Credit Card Clients“ rinkinys [1]. Vieno kliento įvestis X sudaryta iš kredito limito (LIMIT_BAL), demografinių požymių (SEX, EDUCATION, MARRIAGE, AGE), šešių mėnesių mokėjimų būsenų (PAY_0, PAY_2–PAY_6), sąskaitų sumų (BILL_AMT1–BILL_AMT6) ir atliktų mokėjimų sumų (PAY_AMT1–PAY_AMT6). Tikslas Y: 0 – įsipareigojimai vykdomi, 1 – kitą mėnesį nevykdomi.

Pirminė išvestis yra $\hat{p} \in [0,1]$ – prognozuota default tikimybė. Jei taikomas kalibravimas, gaunama $\hat{p}_cal$. Pasirinkus verslo slenkstį t, iš tikimybės gaunama klasė $\hat{y}$: jei $\hat{p}_cal \geq t$, $\hat{y}=1$, kitu atveju $\hat{y}=0$.

## 2.1. Duomenų paruošimas

Planuojamas stratifikuotas 70/15/15 skaidymas: 70 % mokymui, 15 % validavimui ir kalibravimui, 15 % galutiniam testui. Atsitiktinė sėkla fiksuojama. Kategorijų kodavimas,

standartizavimas ir kiti preprocessing parametrai apskaičiuojami tik mokymo imtyje, kad nebūtų duomenų nutekėjimo.

## 3. Galimi sprendimo metodai ir literatūros pagrindimas

| Metodas | Vaidmuo | Kodėl tinka | Ribojimas |
|---|---|---|---|
| Bendras default dažnis | Naivus baseline | Parodo minimalią atskaitos ribą. | Nenaudoja kliento požymių. |
| Logistinė regresija | Pagrindinis baseline | Interpretuojama, natūraliai pateikia tikimybę. | Sunkiau modeliuoja netiesinius ryšius. |
| XGBoost | Pagrindinis intelektualus metodas | Tinka lenteliniams duomenims, modeliuoja netiesiškumą ir požymių sąveikas [2,4]. | Tikimybėms gali reikėti kalibravimo. |
| Random Forest / MLP | Alternatyvos | Leidžia patikrinti, ar kitoks nelinijinis modelis duoda naudą. | RF gali būti mažiau tikslus už boosting; MLP jautresnis masteliui ir hiperparametrams. |

Literatūra pagrindžia kelių modelių palyginimą kredito rizikos uždavinyje. 2025 m. tyrime lyginami Logistic Regression, Random Forest ir XGBoost kalibruotam bei kaštams jautriam kredito default prognozavimui [2]. 2026 m. darbe nagrinėjamas fairness-aware mašininis mokymasis kredito vertinime [3], o kitame 2026 m. tyrime – XGBoost interpretavimo problemos kredito rizikos vertinime [4].

**Metodų pagrindimas šaltiniais.** XGBoost ir Random Forest tinkamumas kredito įsipareigojimų nevykdymo prognozavimui grindžiamas 2025 m. tyrimu, kuriame šie metodai tiesiogiai lyginami su logistine regresija kalibruoto ir kaštams jautraus kredito rizikos vertinimo uždavinyje [2]. XGBoost interpretavimo taikymas kredito rizikai papildomai nagrinėjamas 2026 m. darbe [4]. MLP pasirinkimas grindžiamas pirminiu Yeh ir Lien tyrimu, kuriame tam pačiam UCI kredito kortelių duomenų rinkiniui taikyti neuroninių tinklų ir kiti duomenų gavybos metodai [1]. Fairness vertinimo poreikį kredito scoring uždaviniuose pagrindžia 2026 m. eksperimentinis tyrimas [3].

### 3.1. Pasirinktas sprendimas ir jo privalumai

Pagrindiniu intelektualiuoju metodu pasirenkamas XGBoost, tačiau jo pranašumas turi būti patvirtintas vienodomis eksperimento sąlygomis. Hipotezė: XGBoost dėl netiesinių ryšių ir požymių sąveikų modeliuos kredito riziką geriau už logistinę regresiją pagal PR-AUC, išlaikant priimtiną kalibraciją po kalibravimo. Logistinė regresija išlieka svarbi kaip aiškiai interpretuojamas baseline. XGBoost pranašumas prieš MLP šiame darbe – natūralus tinkamumas struktūriniams lenteliniams duomenims ir mažesnė priklausomybė nuo požymių mastelio; prieš paprastą Random Forest – gradientinis klaidų taisymas. Trūkumas – sudėtingesnis paaiškinamumas ir galimas papildomo tikimybių kalibravimo poreikis.

## 4. Veiksmų eiliškumas ir būsimo algoritmo struktūra

**Algoritmo eiga:**

UCI duomenys → kokybės patikra → stratifikuotas 70/15/15 skaidymas → preprocessing tik pagal mokymo imtį → bendro dažnio ir logistinės regresijos baseline → XGBoost ir alternatyva → validavimo metrikos → tikimybių kalibravimas → slenksčio ir klaidų kainos analizė → grupių analizė → vienkartinis galutinis testas.

Visiems modeliams naudojamos tos pačios mokymo, validavimo ir testo imtys. Hiperparametrai, kalibravimo metodas ir slenkstis parenkami nenaudojant galutinio testo. Taip užtikrinamas korektiškas palyginimas ir atkuriamumas.

### 4.1. Vertinimo metrikos ir eksperimentų planas

- PR-AUC – pagrindinė diskriminacijos metrika esant nesubalansuotoms klasėms.
- Brier score – prognozuotų tikimybių tikslumui ir kalibracijai.
- Kalibracijos kreivė – ar prognozuota tikimybė atitinka stebimą įvykių dažnį.
- Klaidų kaštų kreivė – kaip keičiasi sprendimo kaina keičiant slenkstį t.
- Grupių analizė – metrikos pagal aktualias grupes ir bandymas su demografiniais požymiais bei be jų.
- Atsparumo / abliacijos bandymas – pašalinti dalį požymių arba pakeisti modelio komponentą ir įvertinti rezultato pokytį.

## 5. Pagrindinės formulės

**Logistinės regresijos tikimybė:**

$$z_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \ldots + \beta_p x_{ip}$$

$$\hat{p}_i = 1 / (1 + e^{\wedge}(-z_i))$$

Čia $x_{ij}$ – i-ojo kliento j-asis požymis iš UCI rinkinio; $\beta_0$ – laisvasis narys; $\beta_j$ – mokymo metu nustatomas požymio koeficientas; $\hat{p}_i$ – prognozuota įsipareigojimų nevykdymo tikimybė.

**Sprendimo taisyklė:**

$$\hat{y}_i = 1, \text{ kai } \hat{p}_cal,i \geq t; \text{ kitu atveju } \hat{y}_i = 0$$

t – validavimo duomenimis parinktas slenkstis. Jo pasirinkimas priklauso nuo false positive ir false negative kainos.

**Brier score:**

$$BS = (1/N) \sum_{i=1}^{N} (\hat{p}_i - y_i)^2$$

N – vertinamų klientų skaičius, $\hat{p}_i$ – prognozuota tikimybė, $y_i \in \{0,1\}$ – tikras rezultatas. Mažesnė BS reikšmė reiškia tikslesnes tikimybes.

**Bendra klaidų kaina:**

$$Cost(t) = C_FN \cdot FN(t) + C_FP \cdot FP(t)$$

FN(t) ir FP(t) – klaidingai neigiamų ir klaidingai teigiamų sprendimų skaičius prie slenksčio t; C_FN ir C_FP – jų santykinės kainos. Formulė leidžia slenkstį rinktis ne vien pagal klasifikavimo tikslumą.

**Formulių susiejimas su programos moduliais.** Duomenų paruošimo modulis suformuos požymių matricą X ir tikslinį vektorių Y. Modelių mokymo modulis pagal X apskaičiuos prognozuotas tikimybes $\hat{p}$. Kalibravimo modulis iš jų gaus $\hat{p}$_cal. Vertinimo modulyje bus skaičiuojami PR-AUC, Brier score ir kalibracijos rodikliai. Sprendimo slenksčio modulyje pagal t tikimybės bus paverčiamos klasėmis 0/1, o klaidų kainos modulyje pagal C_FN, C_FP, FN(t) ir FP(t) bus skaičiuojama Cost(t).

### 5.1. Klaidų analizės planas

Galutiniame teste bus atskirai analizuojami false positive ir false negative atvejai. Bus tikrinama, kokiais požymiais pasižymi dažniausiai klaidingai klasifikuojami klientai, ar klaidos nėra susitelkusios konkrečiose klientų grupėse ir kaip jų skaičius bei santykinė kaina keičiasi keičiant sprendimo slenkstį t.

### 5.2. Skaičiavimo biudžetas

Eksperimentai bus atliekami lokaliame kompiuteryje. Kadangi rinkinį sudaro 30 000 įrašų ir 23 aiškinamieji požymiai, GPU ar paskirstyta skaičiavimo infrastruktūra neplanuojama. Vieno modelio mokymas turėtų trukti nuo kelių sekundžių iki kelių minučių, priklausomai nuo metodo ir

hiperparametrų. Hiperparametrų paieškos erdvė bus ribojama, kad visą eksperimentą būtų galima pakartoti tame pačiame kompiuteryje per pagrįstą laiką.

## 6. Rizikos, ribos ir AI naudojimo tikrinimas

Pagrindinės rizikos: istorinio Taivano duomenų rinkinio ribotas perkeliamumas, galimi proxy kintamieji, klasių disbalansas, overfitting ir netinkamai kalibruotos tikimybės. Todėl galutinės išvados bus ribojamos naudojamo rinkinio populiacija ir laikotarpiu, o modelio rezultatas nebus interpretuojamas kaip priežastinis ar automatinis kredito sprendimas.

AI agentas gali būti naudojamas kodo struktūrai, formulių paaiškinimui ir eksperimentų planui rengti, tačiau kiekviena citata, DOI, duomenų rinkinio aprašymas ir rezultatas tikrinamas pirminiame šaltinyje. Sugeneruotas kodas paleidžiamas lokaliai; tikrinamas duomenų skaidymas, preprocessing, metrikų skaičiavimas ir tai, kad testavimo imtis nebūtų panaudota modelio parinkimui.

## Literatūra


[1] Yeh, I.-C., Lien, C.-H. (2009). The comparisons of data mining techniques for the predictive accuracy of probability of default of credit card clients. Expert Systems with Applications, 36(2), 2473–2480. DOI: 10.1016/j.eswa.2007.12.020. UCI dataset DOI: 10.24432/C55S3H.

[2] From Scores to Decisions: Comparing Logistic Regression, Random Forest, and XGBoost for Calibrated, Cost-Sensitive Credit Default Prediction. (2025). Advances in Economics, Management and Political Sciences, 240, 70–79. DOI: 10.54254/2754-1169/2025.BL29296.

[3] Thi Thu, H. G., Doan, T. V., Ban, H.-B., Quy, T. L. (2026). An experimental study on fairness-aware machine learning for credit scoring problems. Digital Finance, 8, Article 35. DOI: 10.1007/s42521-026-00202-6.

[4] Resolving Interpretability Conflicts of Gradient Boosted Decision Trees (XGBoost) in Credit Risk Assessment. (2026). Journal of Organizational and End User Computing, 38(1). DOI: 10.4018/JOEUC.402038.