VILNIUS TECH

Intelektualiosios sistemos

Kredito įsipareigojimų nevykdymo rizikos prognozė

Galutinio egzamino ataskaita

Studentė: Meila Andriuškevičiūtė

Grupė: DISfm-26

2026–2027 m. m.

UCI Default of Credit Card Clients · kalibruota default tikimybė · PR-AUC, Brier score, kalibracija, klaidų kaina

1. Užduotis

Individuali 2026–2027 m. užduotis dalykui „Intelektualiosios sistemos“. Tema: kredito įsipareigojimų nevykdymo rizika. Finansų įstaiga nori numatyti kito mėnesio įsipareigojimų nevykdymo riziką.

Duomenys ir sprendimo tikslas

- Duomenų rinkinys: UCI Default of Credit Card Clients, https://archive.ics.uci.edu/dataset/350/default+of+credit+card+clients
- Prognozuojamas rezultatas: kalibruota įsipareigojimų nevykdymo tikimybė.
- Privalomas baseline: bendras dažnis ir logistinė regresija.
- Svarstytini intelektualieji metodai: SVM, MLP, medžių ansamblis, fuzzy taisyklės. Šiame darbe pasirinkti XGBoost ir Random Forest.
- Pagrindinės vertinimo kryptys: PR-AUC, Brier score, kalibracija ir klaidų kaštų kreivė.
- Duomenų skaidymas: stratifikuotas testas; preprocessing tik mokymo imtyje.
- Svarbiausias probleminis aspektas: teisingumas skirtingoms grupėms ir tikimybės kalibravimas.

Galutinio egzamino reikalavimai

- Įgyvendinti duomenų paruošimo grandinę, baseline ir bent du intelektualiuosius metodus.
- Bent vienam modeliui parodyti formulės ar taisyklės ryšį su konkrečia kodo vieta.
- Palyginti metodus tuo pačiu skaidymu ir tomis pačiomis metrikomis. Hiperparametrų parinkimui nenaudoti galutinio testo.
- Atlikti bent vieną abliaciją ir bent vieną atsparumo bandymą.
- Pateikti rezultatų lentelę, grafiką, klaidų pavyzdžius ir paaiškinti, kodėl metodas laimėjo.
- Pateikti paleidimo instrukciją, priklausomybes, fiksuotas sėklas ir vieną komandą eksperimentui.
- Pateikti AI naudojimo žurnalą.

2. Sprendimo dokumentacija

2.1. Problema

Tikslas – pagal kredito kortelės kliento istorinius duomenis įvertinti kalibruotą tikimybę, kad klientas kitą mėnesį nevykdys finansinių įsipareigojimų. Modelis vertinamas kaip sprendimų palaikymo priemonė, ne automatinė galutinio kredito sprendimo sistema. Rinkinį sudaro 30 000 klientų, iš jų 6 636 (22,12 %) priklauso default klasei.

2.2. Hipotezė

XGBoost dėl netiesinių ryšių ir požymių sąveikų turėtų pranokti logistinę regresiją pagal PR-AUC, išlaikant priimtiną kalibraciją po kalibravimo.

Išvada: hipotezė pasitvirtino. Testo imtyje XGBoost pasiekė PR-AUC 0,5430, Random Forest – 0,5333, logistinė regresija – 0,4795, bendras dažnis – 0,2211. Po isotonic kalibravimo XGBoost Brier score yra 0,1343, ECE – 0,0176.

2.3. Įvestis ir išvestis

Įvestis X: LIMIT_BAL, SEX, EDUCATION, MARRIAGE, AGE, mokėjimų būsenos PAY_1–PAY_6, sąskaitos BILL_AMT1–BILL_AMT6, mokėjimai PAY_AMT1–PAY_AMT6. Tikslas Y: 0 – įsipareigojimai

vykdomi, 1 – kitą mėnesį nevykdomi. Išvestis: $\hat{p} \in [0, 1]$, po kalibravimo $\hat{p}_{cal}$, klasė $\hat{y} = 1$, jei $\hat{p}_{cal} \geq t$.

2.4. Duomenų grandinė

Stratifikuotas 70/15/15 skaidymas, sėkla 42. Mokymas 21 000, validavimas 4 500, testas 4 500. EDUCATION reikšmės 0, 5, 6 sujungtos į 4; MARRIAGE 0 – į 3. Kategorijos koduojamos OneHotEncoder, skaitiniai požymiai logistinei regresijai standartizuojami. Visi preprocessing parametrai skaičiuojami tik mokymo imtyje.

```
UCI duomenys → kokybės patikra → stratifikuotas 70/15/15 →
preprocessing tik pagal mokymą → bendras dažnis + logistinė regresija →
XGBoost + Random Forest → validavimo metrikos → kalibravimas →
slenksčio / kainos analizė → grupės → abliacija / atsparumas → vienkartinis testas
```

2.5. Modeliai

Naivus baseline visiems klientams priskiria mokymo imties default dažnį (0,2212). Logistinė regresija yra interpretuojamas baseline; hiperparametras $C \in \{0{,}1;\ 1;\ 10\}$ ir class_weight parinkti pagal validavimo PR-AUC. XGBoost – pagrindinis intelektualus metodas (n_estimators=150, max_depth=3, learning_rate=0,05). Random Forest – antroji alternatyva (200 medžių, max_depth=8). Kalibratorius (isotonic arba Platt) mokomas tik validavime; visiems modeliams pasirinktas isotonic.

2.6. Formulės ir kodas

Logistinė regresija:

$$z_i = \beta_0 + \beta_1 x_{i1} + \ldots + \beta_p x_{ip}$$
$$\hat{p}_i = 1 / (1 + e^{-z_i})$$

Šios formulės įgyvendintos faile src/formulas.py funkcijose linear_score ir logistic_probability. Validavimo imties aštuoniose eilutėse rankinės tikimybės sutampa su sklearn iki 0.00e+00.

Sprendimo taisyklė, Brier score ir klaidų kaina:

$$\hat{y}_i = 1, \text{ kai } \hat{p}_{cal,i} \geq t; \text{ kitaip } \hat{y}_i = 0$$
$$BS = (1/N)\ \Sigma\ (\hat{p}_i - y_i)^2$$
$$Cost(t) = C_{FN} \cdot FN(t) + C_{FP} \cdot FP(t),\quad C_{FN} = 5,\ C_{FP} = 1$$

XGBoost dvejetainei klasifikacijai naudoja objective='binary:logistic': $z(x) = \Sigma_k f_k(x)$, $\hat{p} = \sigma(z)$. Slenkstis t parenkamas validavime minimizuojant Cost(t).

3. Rezultatai: metodų palyginimas

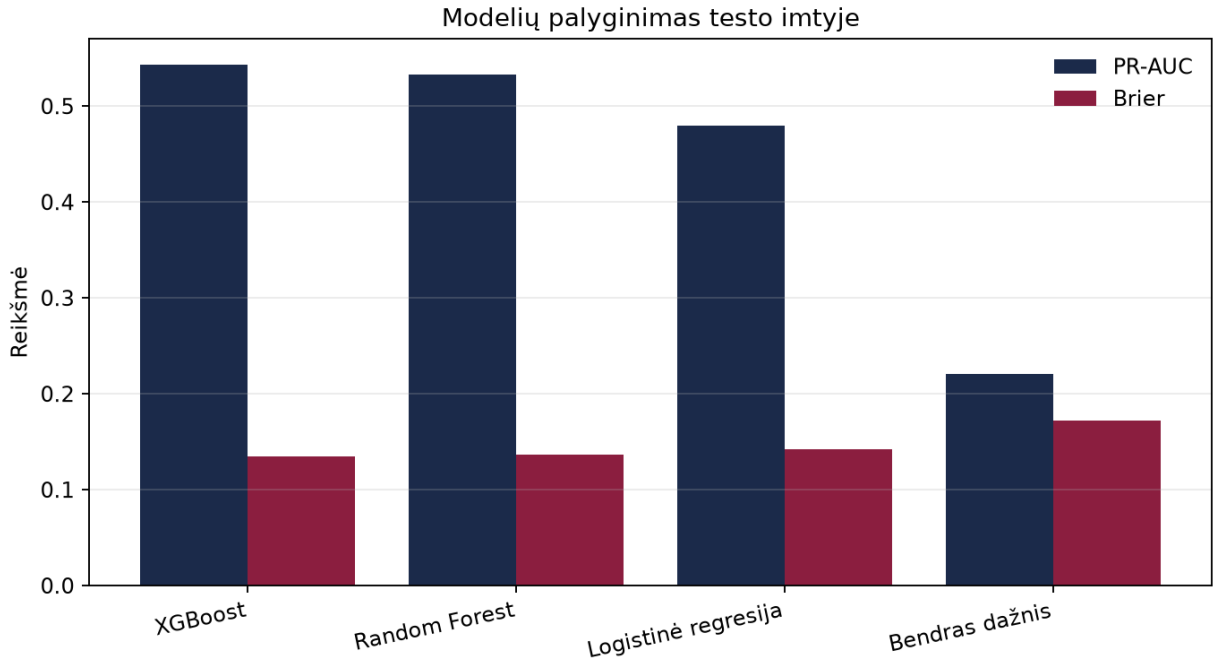
Visi metodai lyginti tomis pačiomis imtimis. Hiperparametrai, kalibratorius ir slenkstis parinkti nenaudojant testo. Pagrindinė diskriminacijos metrika – PR-AUC, nes klasės nesubalansuotos. Accuracy čia klaidina: pastovus „nėra default“ duotų apie 78 %.

Modelis	PR-AUC	ROC-AUC	Brier	ECE	Cost	t	FN	FP
XGBoost	0,5430	0,7820	0,1343	0,018	2529	0,175	321	924
Random Forest	0,5333	0,7782	0,1363	0,015	2520	0,150	209	1475
Logistinė regresija	0,4795	0,7153	0,1426	0,013	2896	0,175	367	1061
Bendras dažnis	0,2211	0,5000	0,1722	0,000	3505	0,050	0	3505

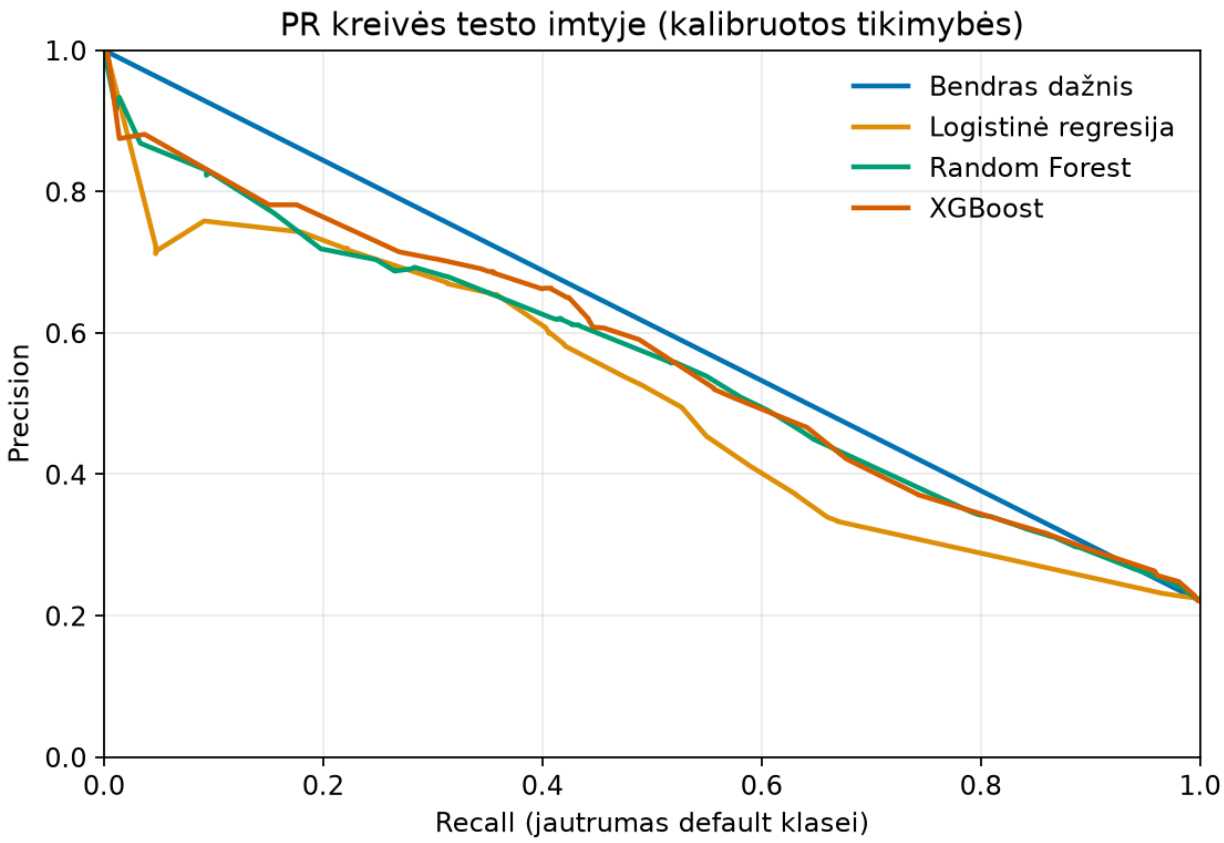
1 lentelė. Kalibruotos tikimybės, testo imtis (n = 4 500). Mažesnis Brier ir ECE – geriau.

XGBoost laimėjo pagal PR-AUC. Random Forest arti jo pagal diskriminaciją, bet turi daugiau FP (1 475 prieš 924) ir žemesnį tikslumą prie savo slenksčio. Logistinė regresija silpnesnė ir pagal PR-AUC, ir pagal Brier. Bendras dažnis PR-AUC sutampa su default dažniu – tai naivi atskaitos riba.

1 pav. PR-AUC ir Brier testo imtyje



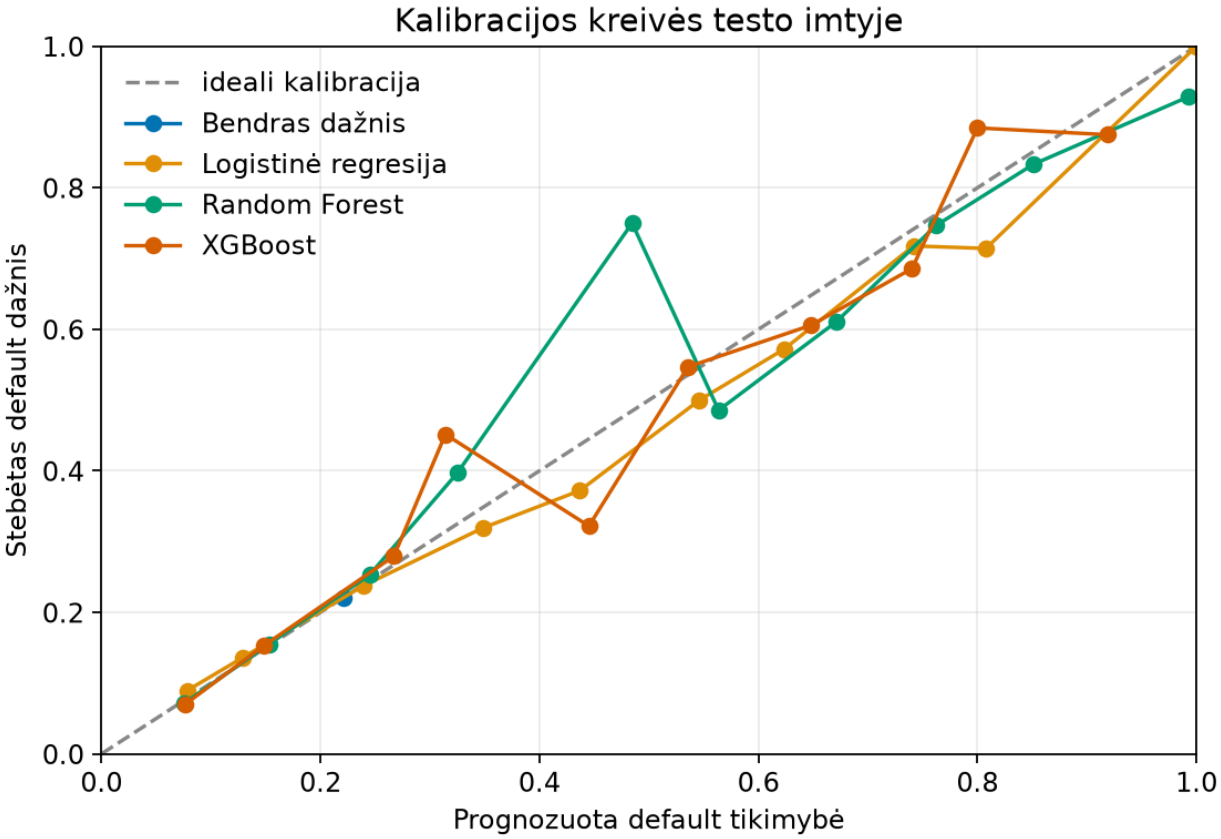
2 pav. Precision–Recall kreivės



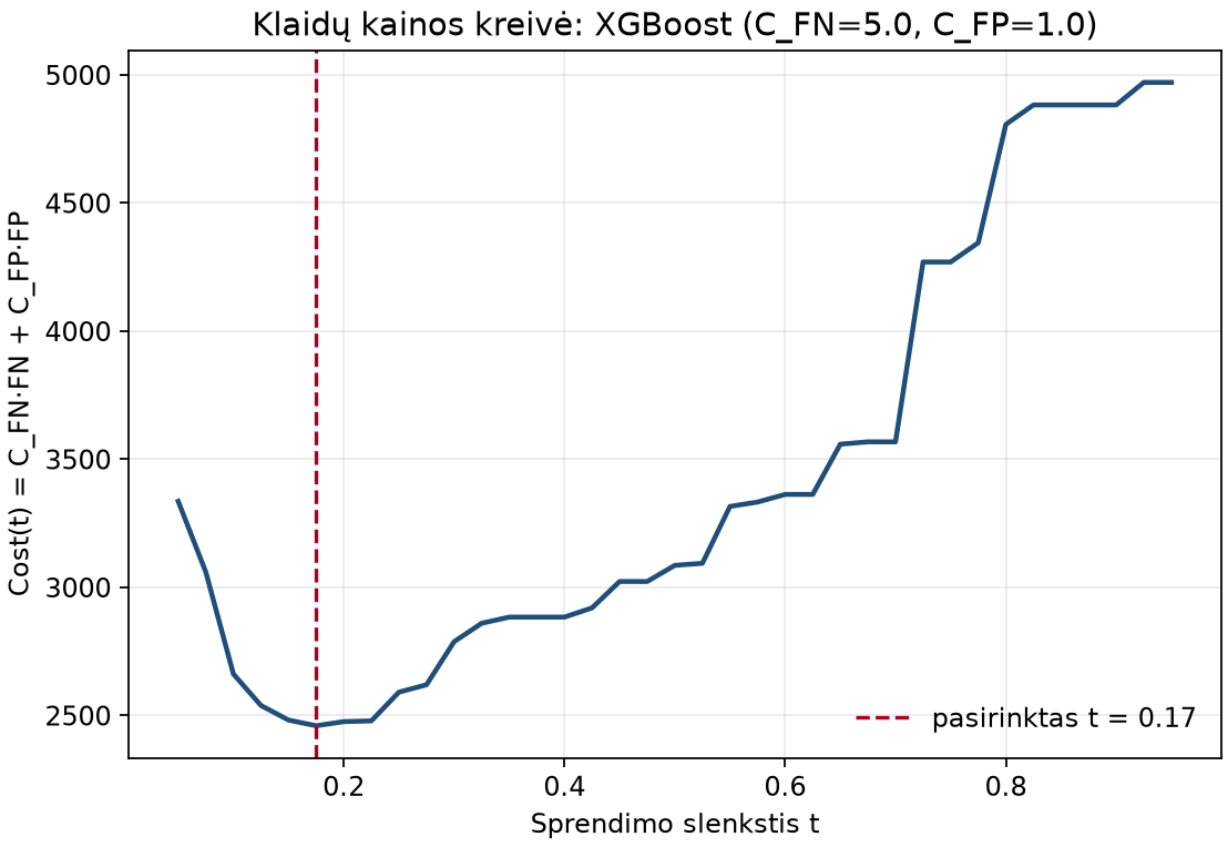
3.1. Kalibracija ir klaidų kaina

Geras surikiavimas pagal riziką nereiškia, kad prognozuota 0,30 tikimybė atitinka 30 % įvykių. Todėl tikimybės kalibruotos isotonic regresija validavimo imtyje. XGBoost Brier po kalibravimo sumažėjo nuo 0,175 iki 0,130 (validavime).

3 pav. Kalibracijos kreivės testo imtyje



4 pav. XGBoost klaidų kainos kreivė; pasirinktas t = 0,175



Slenkstis 0,175 pasirinktas ne pagal accuracy, o pagal Cost(t) su C_FN:C_FP = 5:1. Žemesnis slenkstis padidintų recall, bet ir nepagrįstų ribojimų (FP) skaičių.

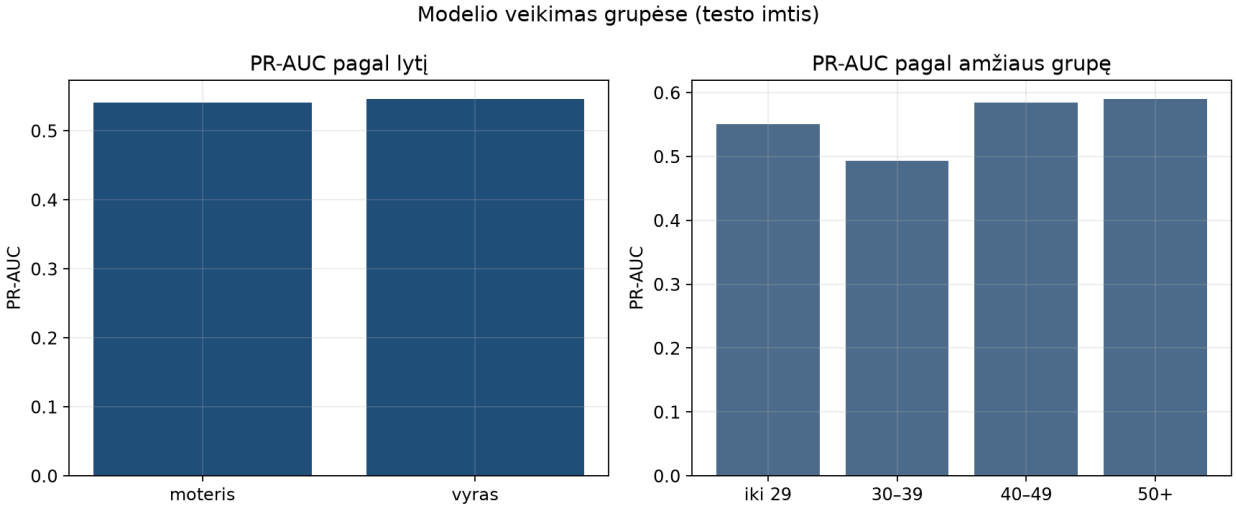
4. Grupės, klaidos, abliacija ir atsparumas

4.1. Veikimas grupėse

Grupė	n	Default dažnis	PR-AUC	Brier	FN dalis	FP dalis
moteris	2704	0,209	0,5411	0,1274	0,338	0,244
vyras	1796	0,239	0,5460	0,1447	0,302	0,295

2 lentelė. XGBoost pagal lytį (testas). PR-AUC panašus (0,541 ir 0,546).

5 pav. PR-AUC pagal lytį ir amžiaus grupę



Amžiaus grupėje 30–39 PR-AUC žemesnis (0,493) nei 50+ (0,590). Skirtumai neįrodo priežastinės diskriminacijos, bet demografiniai požymiai gali būti proxy. Abliacija be demografijos PR-AUC sumažina nedaug (0,562 → 0,553, nekalibruotas XGBoost palyginimas), todėl praktikoje demografiją galima šalinti be didelio nuostolio.

4.2. Klaidų analizė

False negative (praleistas default) brangesnis. FN klientai vidutiniškai turi didesnį limitą ir geresnę PAY_1 būseną nei TP – modelis juos laiko saugesniais. FP klientai dažniau turi teigiamą PAY_1 (vėlavimą) ir mažesnį limitą.

Klaida	LIMIT_BAL	AGE	PAY_1	BILL_AMT1	PAY_AMT1
FN	175670	36,1	-0,38	61193	5270
FP	118766	35,8	0,30	27121	1801
TN	195494	35,5	-0,40	60163	8243
TP	120682	36,2	1,14	45239	2350

3 lentelė. Vidutiniai požymiai pagal TP/TN/FP/FN (testas, XGBoost, t = 0,175).

ID	LIMIT_BAL	AGE	PAY_1	p̂_cal	tikra y
10733	260000	32	0	0,000	1
983	500000	36	-2	0,000	1
18899	140000	28	0	0,027	1
28994	480000	39	0	0,027	1
10671	410000	48	0	0,027	1

4 lentelė. False negative pavyzdžiai: tikras default, modelis neįspėjo.

ID	LIMIT_BAL	AGE	PAY_1	p̂_cal	tikra y
28748	50000	28	3	0,900	0
5593	30000	49	3	0,900	0
7175	20000	36	2	0,800	0
1989	140000	34	2	0,800	0
3873	30000	49	2	0,800	0

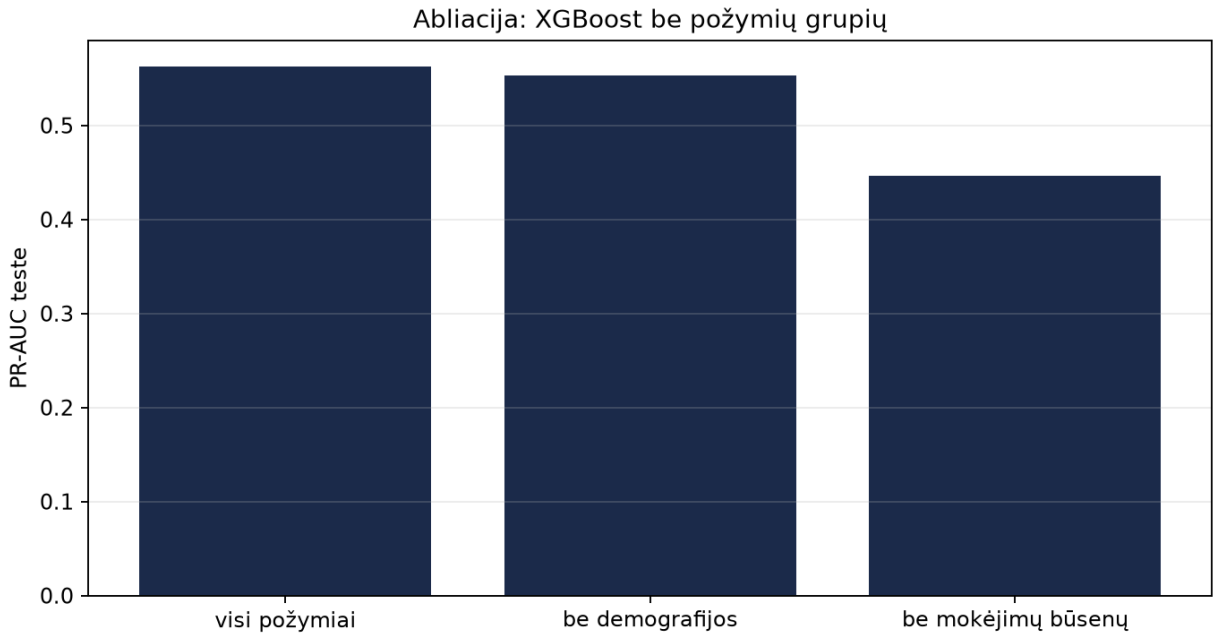
5 lentelė. False positive pavyzdžiai: klientas būtų apribotas be pagrindo.

4.3. Abliacija

Variantas	Pašalinta	PR-AUC teste	Brier
visi požymiai	—	0,5624	0,1788
be demografijos	SEX, EDUCATION, MARRIAGE, AGE	0,5527	0,1738
be mokėjimų būsenų	PAY_1, PAY_2, PAY_3, PAY_4, PAY_5, PAY_6	0,4461	0,1974

6 lentelė. XGBoost abliacija. Ši lentelė naudoja nekalibruotas tikimybes, kad lyginti požymių poveikį.

6 pav. PR-AUC pašalinus požymių grupes



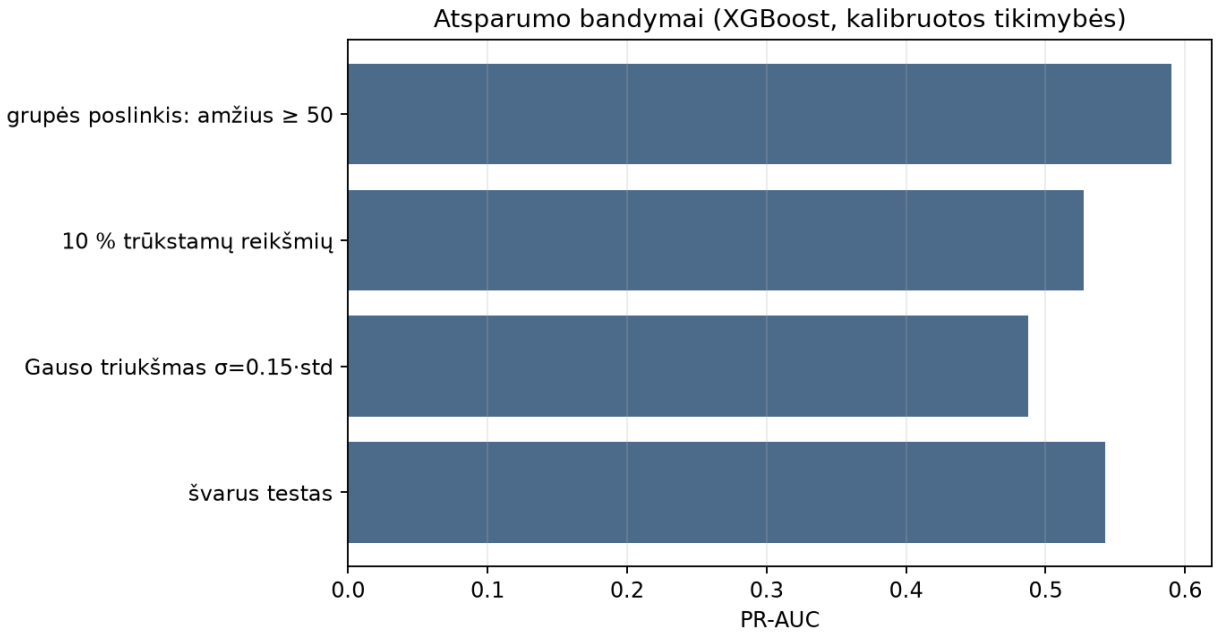
Mokėjimų būsenos yra svarbiausia grupė: be PAY_* PR-AUC krenta iki 0,446. Demografijos pašalinimas pakeičia rezultatą nedaug.

4.4. Atsparumas

Scenarijus	n	PR-AUC	Brier	ECE	Cost
švarus testas	4500	0,5430	0,1343	0,018	2529
Gauso triukšmas σ=0.15·std	4500	0,4875	0,1455	0,043	2981
10 % trūkstamų reikšmių	4500	0,5271	0,1371	0,022	2624
grupės poslinkis: amžius ≥ 50	422	0,5899	0,1468	0,038	274

7 lentelė. Tas pats XGBoost modelis, be pakartotinio mokymo.

7 pav. Atsparumo bandymų PR-AUC



Gauso triukšmas (σ = 0,15 · std) PR-AUC sumažina nuo 0,543 iki 0,487. 10 % atsitiktinai trūkstamų reikšmių poveikis mažesnis (0,527). Amžiaus grupėje ≥ 50 diskriminacija išlieka, bet imtis mažesnė (n = 422).

5. Kodėl XGBoost laimėjo ir kokios ribos

XGBoost pranoko logistinę regresiją, nes kredito vėlavimo istorija ir mokėjimų sumos sąveikauja netiesiškai – tai medžiams natūralu, o logistinei regresijai reikėtų rankinių narių. Random Forest artimas, bet gradientinis klaidų taisymas čia davė nedidelį PR-AUC pranašumą. MLP nebuvo treniruotas šiame paleidime: du intelektualūs metodai tenkina užduotį, o MLP jautresnis masteliui.

- Duomenys surinkti Taivane 2005 m. – rezultatų negalima perkelti į dabartinę Lietuvos rinką.
- Modelis neduoda priežastinio paaiškinimo ir neturi būti vienintelis kredito sprendimas.
- Slenkstis priklauso nuo C_FN ir C_FP; kitos kainos duotų kitą t.
- Isotonic kalibravimas p̂_cal keičia laiptais – panašūs balai gali gauti tą pačią tikimybę.
- Klasių disbalansas (~22 %) daro accuracy klaidinančia metrika.

6. Atkuriamumas

Programinis kodas ir ataskaita: https://github.com/Meilaa/Kredito-sipareigojim-nevykdymo-rizikos-prognoz-

Atsitiktinė sėkla 42. Duomenys atsisiunčiami automatiniu būdu iš UCI (id=350). Viena komanda:

```
python run_experiment.py
```

Svetainė ir Jupyter:

```
streamlit run svetaine.py
jupyter notebook notebooks/egzamino_sprendimas.ipynb
```

Priklausomybės: requirements.txt. Projektas: src/ (duomenys, preprocessing, modeliai, formulės, metrikos), artifacts/ (lentelės, grafikai, results.json). macOS XGBoost gali reikalauti OpenMP: bash scripts/ensure_libomp.sh.

7. AI naudojimo žurnalas

Cursor agentas naudotas kodo struktūrai, svetainei ir ataskaitai. Citatos, DOI, duomenų aprašymas ir skaitiniai rezultatai tikrinti atskirai. Sugeneruotas kodas paleistas lokaliai.

Svarbiausios užklausos

- Sukurti galutinio egzamino sprendimą pagal Word užduotį ir kolokviumo planą.
- Parodyti sprendimą svetainėje, įskaitant kodą.
- Sudėti užduotį, dokumentaciją, grafikus ir lenteles į PDF.

Priimta / atmesta

Priimta: modulinė Python grandinė, XGBoost ir Random Forest, 70/15/15, Streamlit, formulės src/formulas.py. Atmesta: tik Jupyter be svetainės; MLP kaip trečias metodas šiame paleidime.

Patikrintos AI klaidos

- ucimlrepo grąžino stulpelius X1–X23, ne LIMIT_BAL. Pirmas mokymas žlugo su 0 požymių. Pataisyta UCI_X_MAP, patikrinta pagal Yeh ir Lien aprašą.
- pip install xgboost macOS nepaliko libomp.dylib. Patikra: import XGBClassifier po libomp įrašymo.
- Straipsnio [2] PR-AUC ≈ 0,89 neperkeltina į šį UCI rinkinį – DOI patikrintas, metrikos imamos tik iš run_experiment.py.

8. Literatūra

[1] Yeh, I.-C., Lien, C.-H. (2009). The comparisons of data mining techniques for the predictive accuracy of probability of default of credit card clients. Expert Systems with Applications, 36(2), 2473–2480. DOI: 10.1016/j.eswa.2007.12.020. UCI DOI: 10.24432/C55S3H.

[2] Wu, H. (2025). From Scores to Decisions: Comparing Logistic Regression, Random Forest, and XGBoost for Calibrated, Cost-Sensitive Credit Default Prediction. Advances in Economics, Management and Political Sciences, 240, 70–79. DOI: 10.54254/2754-1169/2025.BL29296.

[3] Thi Thu, H. G., Doan, T. V., Ban, H.-B., Quy, T. L. (2026). An experimental study on fairness-aware machine learning for credit scoring problems. Digital Finance, 8, Article 35. DOI: 10.1007/s42521-026-00202-6.

[4] Zhang, C. et al. (2026). Resolving Interpretability Conflicts of Gradient Boosted Decision Trees (XGBoost) in Credit Risk Assessment. Journal of Organizational and End User Computing, 38(1). DOI: 10.4018/JOEUC.402038.